LAPORAN PRAKTIKUM

MACHINE LEARNING

Dosen Pengampu: Asep Erlan Maulana S.Kom., M.Kom.



Disusun oleh:

Nama : Nicko fajar aditya
NIM : 241011400801
Kelas : 05TPLP020

TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PAMULANG
TAHUN 2025/2026

PERTEMUAN 2 DATA COLLECTING

A. LANDASAN TEORI

Data Collecting atau pengumpulan data merupakan tahap awal dalam proses Machine Learning dan analisis data yang bertujuan untuk memperoleh data sebagai dasar dalam melakukan eksplorasi, analisis, serta pengembangan model. Kualitas data yang dikumpulkan sangat berpengaruh terhadap hasil analisis yang diperoleh. Oleh karena itu, data yang digunakan harus relevan dengan permasalahan yang ingin dikaji dan memiliki kualitas yang memadai.

Dalam analisis data, khususnya pada bidang e-commerce, dataset dapat diperoleh dari berbagai sumber, seperti database transaksi, sistem penjualan online, API, hasil survei, maupun platform penyedia dataset. Salah satu platform yang menyediakan berbagai dataset untuk keperluan penelitian dan pembelajaran adalah Kaggle. Platform ini menyediakan dataset dari berbagai bidang yang dapat dimanfaatkan untuk eksplorasi data, analisis statistik, visualisasi data, dan pengembangan model Machine Learning.

Pada praktikum ini, data dikumpulkan dari platform Kaggle dengan menggunakan dataset **E-Commerce Sales Data Analysis and EDA**. Dataset tersebut digunakan sebagai bahan untuk mempelajari karakteristik data penjualan e-commerce serta mengeksplorasi informasi yang terkandung di dalamnya. Melalui dataset ini, analisis dapat diarahkan untuk memahami pola penjualan, membandingkan kinerja produk, serta mengidentifikasi tren transaksi berdasarkan variabel yang tersedia.

Penggunaan dataset ini dalam praktikum bertujuan untuk menerapkan Exploratory Data Analysis (EDA), yaitu proses eksplorasi data yang dilakukan untuk memahami struktur dataset, memeriksa kelengkapan data, mengidentifikasi nilai yang tidak wajar, dan menemukan pola yang dapat memberikan informasi mengenai aktivitas penjualan. Proses tersebut dapat dilakukan melalui pembersihan data, perhitungan statistik deskriptif, serta visualisasi menggunakan grafik dan diagram.

Dengan adanya pengumpulan dan eksplorasi data penjualan e-commerce, praktikum ini diharapkan dapat memberikan pemahaman mengenai pemanfaatan data dalam mendukung pengambilan keputusan bisnis. Hasil analisis dapat menjadi bahan pertimbangan untuk memahami tren penjualan, menentukan produk yang diminati, serta menyusun strategi pemasaran yang lebih tepat berdasarkan temuan dari dataset. Seluruh kesimpulan yang diperoleh harus didasarkan pada hasil pengolahan dan analisis data yang sebenarnya.

B. TUGAS PRAKTIKUM 1. Menentukan Sumber Data

Pada tahap Data Collecting, sumber data yang digunakan dalam praktikum ditentukan terlebih dahulu. Dataset diperoleh dari platform Kaggle, yaitu platform yang menyediakan berbagai dataset dan sumber daya untuk kegiatan analisis data serta Machine Learning.

Dataset yang digunakan adalah:

- Nama Dataset: E-Commerce Sales Data Analysis & EDA
- Sumber: Kaggle
- Pembuat: Mohammad erfan Abbasnehzad
- Kategori: Data Collecting/Pengumpulan Data
- Format : Exploratory Data Analysis (EDA)

Dataset dapat diperoleh melalui halaman Kaggle berikut:

https://www.kaggle.com/datasets/erfan4524/e-commerce-sales-data-analysis-and-eda/data

Pemilihan dataset tersebut disesuaikan dengan topik praktikum karena data yang tersedia memiliki berbagai atribut yang berkaitan dengan kondisi data penjualan dan

2. Tujuan Penggunaan Dataset

Dataset **E-Commerce Sales Data Analysis and EDA** digunakan untuk mempelajari pola dan karakteristik data penjualan pada bidang e-commerce. Data tersebut dapat dimanfaatkan sebagai dasar dalam melakukan analisis terhadap aktivitas penjualan, seperti tren transaksi, jumlah produk terjual, serta hubungan antara variabel yang tersedia dalam dataset.

Dalam praktikum ini, dataset digunakan untuk mempelajari bagaimana data penjualan e-commerce dapat diolah dan dieksplorasi menggunakan metode Exploratory Data Analysis (EDA). Proses analisis dilakukan untuk memahami struktur data, memeriksa kualitas data, serta menemukan pola dan informasi yang dapat membantu menjelaskan kondisi penjualan. Hasil eksplorasi dapat disajikan melalui tabel, perhitungan statistik, dan visualisasi data sesuai dengan kolom yang tersedia.

Tujuan penggunaan dataset dalam praktikum adalah:

A. Memahami proses pengumpulan dataset untuk kebutuhan analisis data.
B. Mempelajari karakteristik data yang berkaitan dengan penjualan e-commerce.
C. Mengetahui pola dan tren penjualan berdasarkan informasi yang tersedia dalam dataset.
D. Menyiapkan dan membersihkan dataset sebagai dasar untuk tahapan analisis data selanjutnya.
E. Mempelajari penerapan Exploratory Data Analysis (EDA) dalam mengidentifikasi pola dan memperoleh informasi dari data penjualan.
F. Memahami bagaimana hasil analisis data dapat digunakan untuk mendukung pengambilan keputusan bisnis.

Dengan demikian, dataset ini tidak hanya digunakan untuk memperoleh informasi mengenai penjualan, tetapi juga sebagai media pembelajaran untuk memahami bagaimana data transaksi e-commerce dapat dimanfaatkan melalui proses eksplorasi, analisis statistik, dan visualisasi data. Hasil analisis diharapkan dapat memberikan gambaran mengenai kondisi penjualan serta menjadi bahan pertimbangan dalam menyusun strategi bisnis berdasarkan temuan dari dataset.

3. Menentukan Kesesuaian Dataset

Setelah dataset ditemukan, dilakukan peninjauan terhadap kesesuaiannya dengan tujuan praktikum. Dataset **E-Commerce Sales Data Analysis and EDA** dipilih karena berkaitan dengan aktivitas penjualan pada platform e-commerce dan dapat digunakan untuk mempelajari pola transaksi serta karakteristik penjualan. Informasi yang dapat dianalisis bergantung pada atribut yang tersedia dalam dataset, seperti tanggal transaksi, nama atau kategori produk, jumlah barang terjual, harga, dan informasi penjualan lainnya.

Keberagaman atribut tersebut membuat dataset sesuai digunakan dalam pembelajaran analisis data karena dapat mencakup data numerik dan data kategorikal. Data numerik dapat digunakan untuk menghitung jumlah penjualan atau nilai transaksi, sedangkan data kategorikal dapat dimanfaatkan untuk membandingkan penjualan berdasarkan produk atau kategori tertentu, apabila kolom tersebut tersedia. Melalui dataset ini, mahasiswa dapat mempelajari penerapan Exploratory Data Analysis (EDA) untuk memahami karakteristik data dan mengidentifikasi pola penjualan.

Pada tahap Data Collecting, fokus utama masih berada pada proses memperoleh dan menentukan dataset yang sesuai dengan tujuan praktikum. Pemeriksaan lebih lanjut, sepertimembaca dataset menggunakan Python, memeriksa jumlah baris dan kolom, mengidentifikasi missing value dan data duplikat, memahami tipe data, melakukan visualisasi, serta menjalankan preprocessing akan dilakukan pada tahap atau pertemuan berikutnya. Tahapan tersebut bertujuan untuk memastikan data siap digunakan dalam proses eksplorasi dan analisis penjualan e-commerce.

4. Identifikasi Awal Dataset

Berdasarkan dataset yang diperoleh, data memiliki informasi mengenai aktivitas penjualan pada bidang e-commerce. Beberapa contoh informasi yang dapat terdapat dalam dataset meliputi tanggal transaksi, nama atau kategori produk, jumlah barang terjual, harga produk, jumlah transaksi, serta nilai penjualan. Informasi tersebut bergantung pada atribut yang tersedia dalam dataset yang digunakan.

Informasi tersebut dapat dimanfaatkan sebagai variabel dalam proses Exploratory Data Analysis (EDA) untuk mempelajari karakteristik data, mengidentifikasi tren penjualan, membandingkan kinerja produk, serta mengetahui pola transaksi berdasarkan informasi yang tersedia. Hasil eksplorasi dapat disajikan dalam bentuk tabel, perhitungan statistik deskriptif, dan visualisasi data untuk mempermudah proses interpretasi.

Pada tahap ini belum dilakukan proses transformasi maupun pembersihan data secara mendalam. Data yang diperoleh masih berupa dataset awal yang akan digunakan sebagai bahan untuk tahap pengolahan data selanjutnya. Tahapan berikutnya meliputi pemeriksaan struktur dataset, identifikasi data kosong dan duplikat, penyesuaian tipe data apabila diperlukan, serta visualisasi untuk mendukung analisis penjualan e-commerce.

C. KESIMPULAN

Berdasarkan praktikum pada Pertemuan 2 mengenai Data Collecting, dapat disimpulkan bahwa pengumpulan data merupakan tahap awal yang penting dalam proses analisis data. Pada praktikum ini, dataset diperoleh dari platform Kaggle dengan menggunakan **E-Commerce Sales Data Analysis and EDA**, yang digunakan untuk mempelajari karakteristik dan pola data penjualan pada bidang e-commerce.

Dataset tersebut dipilih karena sesuai dengan tujuan praktikum, yaitu mempelajari penerapan analisis data menggunakan metode Exploratory Data Analysis (EDA). Informasi yang tersedia dalam dataset dapat digunakan untuk mengeksplorasi pola transaksi, menganalisis tren penjualan, serta membandingkan kinerja produk berdasarkan atribut yang tersedia. Hasil analisis tersebut dapat membantu memberikan pemahaman mengenai aktivitas penjualan dan mendukung pengambilan keputusan bisnis.

Dengan diperolehnya dataset yang sesuai, data tersebut dapat digunakan sebagai dasar untuk tahap berikutnya, seperti Data Loading, pemeriksaan struktur data, identifikasi data kosong atau duplikat, preprocessing, dan eksplorasi data lebih lanjut. Pada Pertemuan 2, pembahasan difokuskan pada proses pengumpulan dan penentuan dataset yang sesuai dengan tujuan praktikum, tanpa membahas secara mendalam proses pemuatan maupun pengolahan data.

PERTEMUAN 4 DATA LOADING

A. LANDASAN TEORI

Data Loading merupakan salah satu tahap awal dalam proses pengolahan data pada Machine Learning. Tahap ini dilakukan setelah data berhasil dikumpulkan dari sumber yang telah ditentukan. Data yang telah diperoleh perlu dimasukkan terlebih dahulu ke dalam lingkungan pemrograman agar dapat digunakan pada tahapan pengolahan berikutnya. Dengan adanya proses Data Loading, dataset yang masih berupa file dapat diakses dan disimpan ke dalam bentuk data yang dapat diproses oleh program.

Pada praktikum ini, dataset yang digunakan memiliki format CSV (CommaSeparated Values). Format CSV merupakan salah satu format yang umum digunakan untuk menyimpan data berbentuk tabel, karena setiap baris dapat merepresentasikan suatu data dan setiap kolom merepresentasikan atribut atau variabel tertentu. Proses Data Loading dilakukan menggunakan bahasa pemrograman Python dengan bantuan library Pandas. Pandas menyediakan struktur data seperti DataFrame

yang memungkinkan data berbentuk tabel disimpan dan digunakan dalam program untuk proses pengolahan pada tahap selanjutnya.

Selain Pandas, praktikum ini menggunakan Jupyter Notebook sebagai lingkungan untuk menulis dan menjalankan kode Python. Jupyter Notebook memungkinkan kode dijalankan secara bertahap melalui beberapa cell dan hasil eksekusinya dapat langsung ditampilkan. Dalam proses Data Loading, Pandas menyediakan fungsi read_csv() yang digunakan untuk membaca file CSV. Dataset yang telah dibaca kemudian disimpan ke dalam variabel df dalam bentuk DataFrame sehingga dataset telah tersedia di dalam lingkungan Python.

Tujuan utama dari Data Loading adalah memastikan bahwa dataset dapat diakses oleh program dan berhasil dimasukkan ke dalam lingkungan pengolahan data. Tahap ini belum berfokus pada analisis isi dataset. Oleh karena itu, perintah untuk mengetahui jumlah baris dan kolom, tipe data, statistik deskriptif, distribusi data, missing value, data duplikat, korelasi, maupun visualisasi tidak menjadi bagian utama dari Data Loading. Pemeriksaan dan analisis tersebut akan dilakukan pada tahap Exploratory Data Analysis (EDA).

B. TUGAS PRAKTIKUM

Pada Pada praktikum Data Loading, proses dilakukan menggunakan Jupyter Notebook dengan bahasa pemrograman Python. Dataset yang digunakan merupakan **E-Commerce Sales Data Analysis and EDA** yang sebelumnya telah diperoleh dari platform Kaggle. Dataset tersebut digunakan sebagai bahan pembelajaran untuk memahami karakteristik data penjualan e-commerce dan mempelajari pola transaksi yang terdapat di dalamnya. Selanjutnya, dataset dimuat ke dalam lingkungan Python agar dapat digunakan dalam proses analisis menggunakan metode Exploratory Data Analysis (EDA), seperti pemeriksaan struktur data, analisis tren penjualan, dan visualisasi data pada tahap berikutnya.

1. Menyiapkan Jupyter Notebook

Tahap pertama adalah menyiapkan Jupyter Notebook sebagai lingkungan untuk menjalankan program Python. Jupyter Notebook digunakan karena kode dapat ditulis dan dijalankan secara bertahap melalui beberapa cell. Setiap cell dapat digunakan untuk menjalankan perintah tertentu sehingga proses Data Loading dapat dilakukan dengan lebih terstruktur.

Penggunaan Jupyter Notebook juga memudahkan proses dokumentasi praktikum karena kode program dan hasil eksekusinya dapat berada dalam satu notebook. Dengan demikian, proses yang dilakukan selama praktikum dapat disimpan dan digunakan kembali pada tahap pengolahan data berikutnya.

2. Menyiapkan Library Pandas

Setelah Jupyter Notebook siap digunakan, langkah berikutnya adalah memanggil library Pandas. Pandas diperlukan karena proses pembacaan dataset CSV dilakukan menggunakan fungsi yang tersedia pada library tersebut.

Kode yang digunakan adalah:

```
import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)
```

Pada kode tersebut, pandas diimpor dan diberi alias pd. Penggunaan alias tersebut bertujuan agar pemanggilan fungsi Pandas menjadi lebih singkat. Setelah library berhasil diimpor, fungsi-fungsi yang tersedia di dalam Pandas dapat digunakan untuk melakukan proses Data Loading.

3. Menentukan Lokasi Dataset

Dataset yang telah diperoleh dari Kaggle disimpan pada lokasi yang dapat diakses oleh Jupyter Notebook. Lokasi file perlu diperhatikan karena Python harus mengetahui tempat dataset berada sebelum proses pembacaan dilakukan.

Dataset yang digunakan dalam praktikum adalah E-Commerce Sales Data Analysis and EDA dengan format file CSV. Apabila dataset disimpan di dalam folder Dataset, maka lokasi file dapat dituliskan pada fungsi read_csv() menggunakan library Pandas. Fungsi tersebut digunakan untuk membaca file CSV dan memuat data ke dalam DataFrame agar dapat digunakan pada tahap analisis data berikutnya.

4. Membaca Dataset

Setelah library dan lokasi dataset telah disiapkan, dataset dapat dibaca menggunakan fungsi read_csv().

```
df = pd.read_csv('/datasets/e-commerce-sales-data-analysis-and-eda/clean_final_data.csv')
```

Pada kode tersebut, pd.read_csv() digunakan untuk membaca file CSV. Hasil pembacaan kemudian disimpan ke dalam variabel df. Variabel tersebut selanjutnya menjadi objek DataFrame yang berisi dataset yang telah dimuat ke dalam Python.

Proses ini merupakan inti dari Data Loading karena sebelumnya dataset masih berada dalam bentuk file, sedangkan setelah kode dijalankan, data sudah tersedia di dalam lingkungan Python dan dapat digunakan untuk proses selanjutnya.

5. Menyimpan Dataset dalam Bentuk DataFrame

Setelah file CSV berhasil dibaca, dataset disimpan dalam bentuk DataFrame dengan nama df. DataFrame merupakan struktur data dari Pandas yang digunakan untuk menyimpan data berbentuk tabel.

Dengan menggunakan DataFrame, dataset dapat digunakan pada berbagai tahapan pengolahan data berikutnya. Misalnya, pada tahap EDA nantinya DataFrame dapat digunakan untuk melakukan pemeriksaan karakteristik data, melihat distribusi data, mencari nilai yang hilang, serta membuat visualisasi.

Namun, pada tahap Data Loading belum dilakukan proses-proses tersebut. DataFrame pada tahap ini hanya dipersiapkan sebagai objek data yang akan digunakan pada tahap berikutnya.

6. Memastikan Dataset Berhasil Dimuat

Setelah proses pembacaan dilakukan, dataset dapat ditampilkan untuk memastikan bahwa file telah berhasil dimuat ke dalam Jupyter Notebook.

[5]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 49222 entries, 0 to 49221
Data columns (total 17 columns):
 #   Column           Non-Null Count  Dtype  
---  ------           --------------  -----  
 0   OrderID          49222 non-null  int64  
 1   CustomerID       49222 non-null  int64  
 2   OrderDate        49222 non-null  object 
 3   ProductID        49222 non-null  int64  
 4   Quantity         49222 non-null  float64
 5   Discount         49222 non-null  float64
 6   PaymentMethod    49222 non-null  object 
 7   Status           49222 non-null  object 
 8   Age              49222 non-null  float64
 9   City             49222 non-null  object 
 10  SignupDate       49222 non-null  object 
 11  CustomerSegment  49222 non-null  object 
 12  ProductName      49222 non-null  object 
 13  Category         49222 non-null  object 
 14  UnitPrice        49222 non-null  float64
 15  Sales            49222 non-null  float64
 16  OrderValue       49222 non-null  float64
dtypes: float64(6), int64(3), object(8)
memory usage: 6.4+ MB
```

[6]:
```
df.describe()
```

[6]:

	OrderID	CustomerID	ProductID	Quantity	Discount	Age	UnitPrice	Sales	OrderValue
count	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000
mean	525007.608366	105002.304356	2009.460160	1.881923	7.485576	41.283369	40.286579	69.985576	69.985576
std	14435.345449	2888.912895	5.578603	1.079382	7.754378	13.681355	42.613062	94.483273	94.483273
min	500001.000000	100001.000000	2001.000000	-2.000000	0.000000	18.000000	7.000000	-170.000000	-170.000000
25%	512507.250000	102504.000000	2004.000000	1.000000	0.000000	29.000000	11.000000	17.000000	17.000000
50%	525016.500000	105005.000000	2008.000000	2.000000	5.000000	41.000000	28.000000	38.000000	38.000000
75%	537506.750000	107497.000000	2014.000000	2.000000	10.000000	53.000000	58.000000	84.000000	84.000000
max	550000.000000	110000.000000	2020.000000	5.000000	30.000000	65.000000	260.000000	1300.000000	1300.000000

Perintah df digunakan untuk menampilkan isi DataFrame yang telah dibuat. Apabila data dapat ditampilkan tanpa terjadi kesalahan, maka dapat diketahui bahwa proses pembacaan dataset telah berhasil dilakukan.

Pengecekan ini hanya bertujuan untuk memastikan keberhasilan proses pemuatan data. Pemeriksaan yang lebih mendalam mengenai struktur dan karakteristik dataset akan dilakukan pada tahap EDA.

7. Hasil Data Loading

Berdasarkan proses yang dilakukan, dataset E-Commerce Sales Data Analysis & EDA Dataset berhasil dimasukkan ke dalam Jupyter Notebook menggunakan library Pandas. File CSV berhasil dibaca menggunakan fungsi pd.read_csv() dan hasilnya disimpan dalam DataFrame dengan nama df.

Dengan demikian, dataset sudah tersedia di dalam lingkungan Python dan siap digunakan pada tahap berikutnya. Tahap selanjutnya adalah melakukan Exploratory Data Analysis (EDA) untuk memahami isi, struktur, karakteristik, serta kondisi dataset secara lebih mendalam.

C. KESIMPULAN

Data Loading merupakan tahap yang dilakukan untuk memasukkan dataset ke dalam lingkungan pemrograman sebelum data digunakan pada proses pengolahan dan analisis lebih lanjut. Pada praktikum ini, proses Data Loading dilakukan menggunakan Jupyter Notebook sebagai lingkungan untuk menjalankan kode Python dan library Pandas sebagai library yang digunakan untuk membaca dataset.

Dataset yang digunakan adalah E-Commerce Sales Data Analysis & EDA Dataset yang diperoleh dari Kaggle dalam format CSV. Dataset tersebut dibaca menggunakan fungsi pd.read_csv() dan kemudian disimpan ke dalam variabel df yang berbentuk DataFrame. Dengan proses tersebut, dataset yang sebelumnya tersimpan sebagai file telah berhasil dimasukkan ke dalam lingkungan Python sehingga dapat digunakan pada tahapan berikutnya.

Penggunaan Jupyter Notebook memberikan kemudahan karena kode dapat dijalankan secara bertahap dan hasilnya dapat langsung dilihat pada notebook yang sama. Hal tersebut juga membuat proses praktikum lebih terstruktur karena kode, hasil eksekusi, dan penjelasan dapat disimpan dalam satu dokumen.

Pada tahap ini, fokus utama hanya pada proses pemuatan dataset, bukan pada analisis data. Oleh karena itu, pemeriksaan seperti jumlah baris dan kolom, tipe data, statistik deskriptif, missing value, data duplikat, distribusi data, serta visualisasi belum dilakukan. Pemeriksaan tersebut akan menjadi bagian dari tahap Exploratory Data Analysis (EDA).

Dengan berhasilnya proses Data Loading, dataset telah tersedia dalam bentuk DataFrame dan siap digunakan untuk tahap selanjutnya. Tahapan berikutnya adalah EDA yang bertujuan untuk memahami kondisi dan karakteristik dataset sebelum dilakukan proses preprocessing dan pembangunan model Machine Learning.

PERTEMUAN 5 EXPLORATORY DATA ANALYSIS

A. LANDASAN TEORI

Exploratory Data Analysis (EDA) merupakan tahap eksplorasi data yang dilakukan untuk memahami karakteristik, struktur, dan kondisi dataset sebelum digunakan dalam proses Machine Learning. Tahap ini bertujuan untuk memperoleh gambaran awal mengenai data, menemukan permasalahan yang mungkin terdapat di dalamnya, serta membantu menentukan langkah pengolahan data yang sesuai. Melalui EDA, peneliti dapat mengetahui apakah dataset memiliki nilai yang hilang, data duplikat, distribusi yang tidak seimbang, maupun nilai ekstrem yang perlu diperhatikan.

Dalam proses Machine Learning, EDA memiliki peran penting karena kualitas dan karakteristik data dapat memengaruhi proses pembentukan model. Dataset yang telah berhasil dimuat belum tentu siap digunakan secara langsung. Oleh karena itu, diperlukan pemeriksaan lebih lanjut untuk memahami jumlah data, jenis variabel, ringkasan statistik, dan pola yang terdapat dalam dataset.

EDA dapat dilakukan menggunakan berbagai fungsi dari library Pandas, seperti shape, info(), head(), dan describe(). Fungsi shape digunakan untuk mengetahui jumlah baris dan kolom, sedangkan info() memberikan informasi mengenai struktur dataset, tipe data, serta jumlah nilai yang tidak kosong. Fungsi head() digunakan untuk melihat beberapa baris awal dataset, sementara describe() memberikan ringkasan statistik deskriptif untuk membantu memahami karakteristik variabel. Selain itu, visualisasi menggunakan Matplotlib dan Seaborn dapat dilakukan melalui histogram, box plot,

count plot, serta heatmap korelasi untuk melihat distribusi data, indikasi outlier, jumlah data pada setiap kategori, dan hubungan linear antarvariabel numerik.

Pada praktikum ini, EDA dilakukan menggunakan Jupyter Notebook dengan bahasa pemrograman Python. Dataset yang digunakan adalah Stroke Risk Prediction Dataset yang diperoleh dari Kaggle. Eksplorasi dilakukan untuk memahami kondisi dataset sebelum melanjutkan ke tahap preprocessing dan pembangunan model klasifikasi risiko stroke. Hasil EDA tidak secara langsung membuktikan hubungan sebab-akibat ataupun menentukan diagnosis medis, tetapi memberikan gambaran awal mengenai data yang akan digunakan dalam penelitian.

B. TUGAS PRAKTIKUM

Pada praktikum ini, proses Exploratory Data Analysis dilakukan menggunakan Jupyter Notebook dengan bantuan library Pandas, Matplotlib, dan Seaborn. Dataset Stroke Risk Prediction yang sebelumnya telah dimuat ke dalam DataFrame df diperiksa untuk mengetahui struktur, karakteristik, kelengkapan, distribusi, dan hubungan antarfiturnya.

1. Memeriksa Ukuran Dataset

Langkah pertama adalah mengetahui jumlah baris dan kolom yang terdapat dalam dataset. Pemeriksaan ini dilakukan menggunakan atribut shape.

```
print("ukuran data")
print("baris :", df.shape[0])
print("kolom:", df.shape[1])
ukuran data
Baris : 49222
kolom : 16
```

Atribut df.shape menghasilkan informasi mengenai dimensi dataset, dengan nilai pertama menunjukkan jumlah baris dan nilai kedua menunjukkan jumlah kolom.

Berdasarkan hasil praktikum, dataset memiliki 49.222 baris dan 16 kolom. Informasi tersebut memberikan gambaran mengenai ukuran data yang akan dieksplorasi lebih lanjut. Setiap baris merepresentasikan satu entri data pasien, sedangkan kolom berisi atribut yang berkaitan dengan karakteristik pasien dan risiko stroke.

2. Memeriksa Struktur dan Tipe Data

Setelah mengetahui ukuran dataset, langkah berikutnya adalah memeriksa struktur dan tipe data menggunakan fungsi info().

```
[5]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 49222 entries, 0 to 49221
Data columns (total 17 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   OrderID          49222 non-null  int64
 1   CustomerID       49222 non-null  int64
 2   OrderDate        49222 non-null  object
 3   ProductID        49222 non-null  int64
 4   Quantity         49222 non-null  float64
 5   Discount         49222 non-null  float64
 6   PaymentMethod    49222 non-null  object
 7   Status           49222 non-null  object
 8   Age              49222 non-null  float64
 9   City             49222 non-null  object
 10  SignupDate       49222 non-null  object
 11  CustomerSegment  49222 non-null  object
 12  ProductName      49222 non-null  object
 13  Category         49222 non-null  object
 14  UnitPrice        49222 non-null  float64
 15  Sales            49222 non-null  float64
 16  OrderValue       49222 non-null  float64
dtypes: float64(6), int64(3), object(8)
memory usage: 6.4+ MB
```

Fungsi info() menampilkan informasi mengenai jumlah entri, jumlah kolom, nama kolom, jumlah nilai yang tidak kosong, tipe data, serta penggunaan memori. Informasi ini berguna untuk mengetahui jenis variabel yang terdapat dalam dataset dan melihat kolom yang memiliki nilai kosong.

Berdasarkan hasil pemeriksaan, dataset memiliki 49.222 entri dan 16 kolom. Kolom-kolomnya memiliki tipe data numerik, seperti int64 dan float64, serta tipe object yang umumnya digunakan untuk menyimpan data kategorikal berbentuk teks.

Pemeriksaan ini penting karena fitur numerik dan kategorikal dapat membutuhkan penanganan yang berbeda pada tahap preprocessing. Sebagai contoh, fitur Age berbentuk numerik, sedangkan fitur Gender dan Country berbentuk kategorikal.

3. Melihat Sampel Data

Untuk mengetahui gambaran awal mengenai isi dataset, digunakan fungsi head().

```
[4]: df.head()
```

[4]:

	OrderID	CustomerID	OrderDate	ProductID	Quantity	Discount	PaymentMethod	Status	Age	City	SignupDate	CustomerSegment	ProductName	Cate
0	500001	103695	2025-08-28	2003	4.0	10.0	Gateway	Completed	36.0	Qom	2024-03-05	Regular	USB-C Cable	Access
1	500002	107935	2024-05-31	2014	1.0	10.0	Wallet	Completed	49.0	Kerman	2025-06-04	Regular	Backpack	Access
2	500003	105141	2025-08-10	2002	1.0	20.0	CardToCard	Completed	36.0	Tehran	2025-10-19	Regular	Mechanical Keyboard	Electr
3	500004	108780	2024-10-11	2012	1.0	10.0	Gateway	Completed	45.0	Shiraz	2023-12-07	Regular	Office Chair	H C
4	500005	101187	2024-02-19	2008	2.0	0.0	Gateway	Completed	24.0	Karaj	2023-12-02	Regular	Phone Case	Access

Secara default, fungsi tersebut menampilkan lima baris pertama dari DataFrame. Hasilnya dapat digunakan untuk melihat contoh nilai pada setiap kolom, memahami susunan tabel, dan mengenali bentuk data yang akan dianalisis.

Pada dataset E-Commerce Sales Data Analysis & EDA, beberapa kolom yang terlihat antara lain Order id, customer id, orderdate, ProductID, Quantity, Discount, payment method, serta berbagai indikator e-commerce lainnya. Dataset juga memiliki kolom target Data Analysis yang digunakan dalam proses klasifikasi.

Melalui pemeriksaan sampel data, peneliti dapat memperoleh gambaran awal mengenai isi dataset tanpa harus menampilkan seluruh baris data.

4. Melakukan Analisis Statistik Deskriptif

Tahap berikutnya adalah melihat ringkasan statistik menggunakan fungsi describe(include="all").

```
df.describe(include="all")
```

	OrderID	CustomerID	ProductID	Quantity	Discount	Age	UnitPrice	Sales	OrderValue
count	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000	49222.000000
mean	525007.608366	105002.304356	2009.460160	1.881923	7.485576	41.283369	40.286579	69.985576	69.985576
std	14435.345449	2888.912895	5.578603	1.079382	7.754378	13.681355	42.613062	94.483273	94.483273
min	500001.000000	100001.000000	2001.000000	-2.000000	0.000000	18.000000	7.000000	-170.000000	-170.000000
25%	512507.250000	102504.000000	2004.000000	1.000000	0.000000	29.000000	11.000000	17.000000	17.000000
50%	525016.500000	105005.000000	2008.000000	2.000000	5.000000	41.000000	28.000000	38.000000	38.000000
75%	537506.750000	107497.000000	2014.000000	2.000000	10.000000	53.000000	58.000000	84.000000	84.000000
max	550000.000000	110000.000000	2020.000000	5.000000	30.000000	65.000000	260.000000	1300.000000	1300.000000

Parameter include="all" digunakan agar ringkasan statistik mencakup kolom numerik maupun kategorikal. Untuk kolom numerik, hasilnya dapat menampilkan jumlah data yang tersedia (count), rata-rata (mean), standar deviasi (std), nilai minimum (min), kuartil, dan nilai maksimum (max). Untuk kolom kategorikal, hasilnya dapat mencakup jumlah data, banyak kategori unik, kategori yang paling sering muncul, dan frekuensinya.

Statistik deskriptif membantu memahami rentang nilai, kecenderungan pusat data, dan variasi pada setiap fitur. Informasi tersebut juga dapat membantu menemukan nilai yang perlu diperiksa lebih lanjut, misalnya nilai yang terlalu jauh dari rentang mayoritas data.

Namun, statistik deskriptif tidak secara otomatis menentukan bahwa suatu nilai salah atau merupakan outlier. Penilaian tersebut tetap perlu mempertimbangkan karakteristik fitur dan konteks datanya.

5. Memeriksa Data Duplikat

Pemeriksaan data duplikat dilakukan untuk mengetahui apakah terdapat baris yang memiliki isi identik dalam dataset.

```
print("jumlah baris duplikat:")df.duplicated().sum())
jumlah baris duplikat: 0
```

Fungsi duplicated() digunakan untuk menandai baris yang merupakan duplikat berdasarkan seluruh kolom, sedangkan sum() menghitung jumlah baris yang terdeteksi sebagai duplikat.

Berdasarkan hasil praktikum, jumlah baris duplikat adalah 0. Artinya, tidak ditemukan baris yang sepenuhnya duplikat berdasarkan pemeriksaan tersebut.

Pemeriksaan ini penting karena duplikasi dapat memengaruhi distribusi data dan berpotensi menyebabkan pengamatan tertentu terhitung lebih dari satu kali. Meskipun demikian, tidak ditemukannya duplikasi seluruh baris tidak menjamin bahwa setiap nilai atau setiap identitas pasien pasti unik dalam semua aspek.

6. Memeriksa Missing Value

Missing value merupakan kondisi ketika suatu kolom memiliki nilai yang tidak tersedia pada sebagian baris. Pemeriksaan ini dilakukan menggunakan isnull() dan sum().

```
df.isnull().sum()
```

```
OrderID           0
CustomerID        0
OrderDate         0
ProductID         0
Quantity          0
Discount          0
PaymentMethod     0
Status            0
Age               0
City              0
SignupDate        0
CustomerSegment   0
ProductName       0
Category          0
UnitPrice         0
Sales             0
OrderValue        0
dtype: int64
```

Kode tersebut menghitung jumlah nilai kosong pada setiap kolom, kemudian hanya menampilkan kolom yang memiliki missing value lebih dari nol. Langkah ini membantu mengidentifikasi fitur yang memerlukan perhatian pada tahap preprocessing.

Hasil tersebut menunjukkan bahwa beberapa fitur memiliki nilai yang tidak lengkap. Kondisi ini perlu diperhatikan karena sebagian algoritma Machine Learning tidak dapat langsung memproses missing value tanpa penanganan yang sesuai.

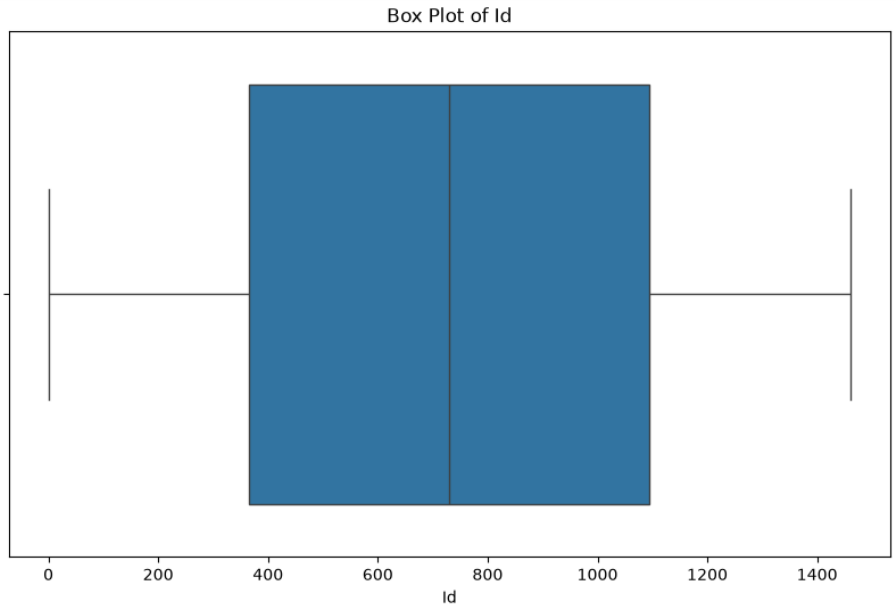
Pada tahap EDA, tujuan pemeriksaan ini adalah mengidentifikasi keberadaan dan jumlah nilai kosong. Pengisian missing value belum dilakukan pada tahap ini, melainkan akan dibahas pada tahap preprocessing.

7. Mengidentifikasi Indikasi Outlier Menggunakan Box Plot

Selain histogram, praktikum ini menggunakan box plot untuk mengeksplorasi penyebaran fitur numerik dan mengidentifikasi nilai yang berpotensi menjadi outlier.

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

for feature in numeric_features:
 plt.figure(figsize=(10, 6))
 sns.boxplot(x=df[feature])
 plt.title(f'Box Plot of {feature}')
 plt.show()
```



Kode tersebut terlebih dahulu memilih kolom dengan tipe data numerik menggunakan select_dtypes(). Selanjutnya, perulangan for digunakan untuk membuat box plot bagi setiap fitur numerik.

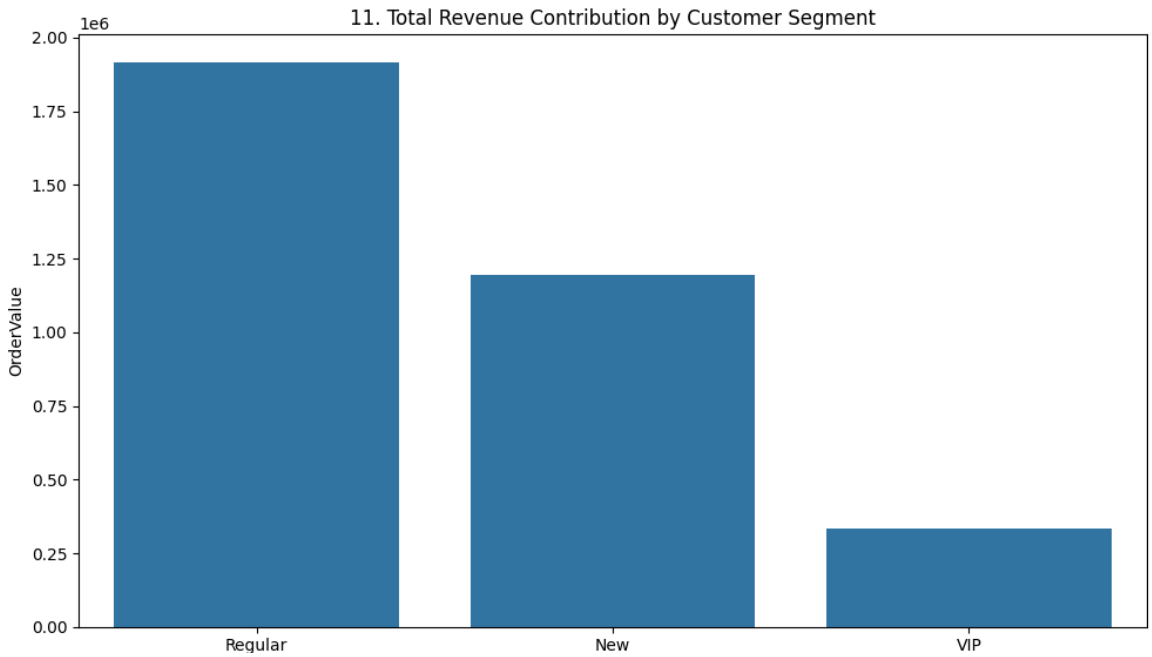
Box plot menampilkan median, kuartil, rentang antarkuartil (interquartile range atau IQR), serta titik yang berada di luar batas whisker. Titik-titik di luar whisker dapat menjadi indikasi outlier berdasarkan aturan statistik box plot, tetapi belum tentu merupakan kesalahan data.

Dalam dataset ini, box plot digunakan untuk mengeksplorasi fitur numerik, termasuk BMI. Nilai ekstrem perlu ditinjau berdasarkan karakteristik fitur sebelum diputuskan apakah perlu dipertahankan atau ditangani. Pada tahap EDA, prosesnya masih berupa identifikasi dan pemeriksaan, bukan penghapusan outlier secara otomatis.

9. Memvisualisasikan Distribusi Kelas Target

Selain menggunakan tabel frekuensi, distribusi target juga divisualisasikan menggunakan count plot.

```
fig = plt.figure(figsize=(10,6))
sns.barplot(data=df, x='CustomerSegment', y='OrderValue', estimator='sum', errorbar=None)
plt.title(f'{plot_no}. Total Revenue Contribution by Customer Segment')
show_fig()
plot_no += 1
```



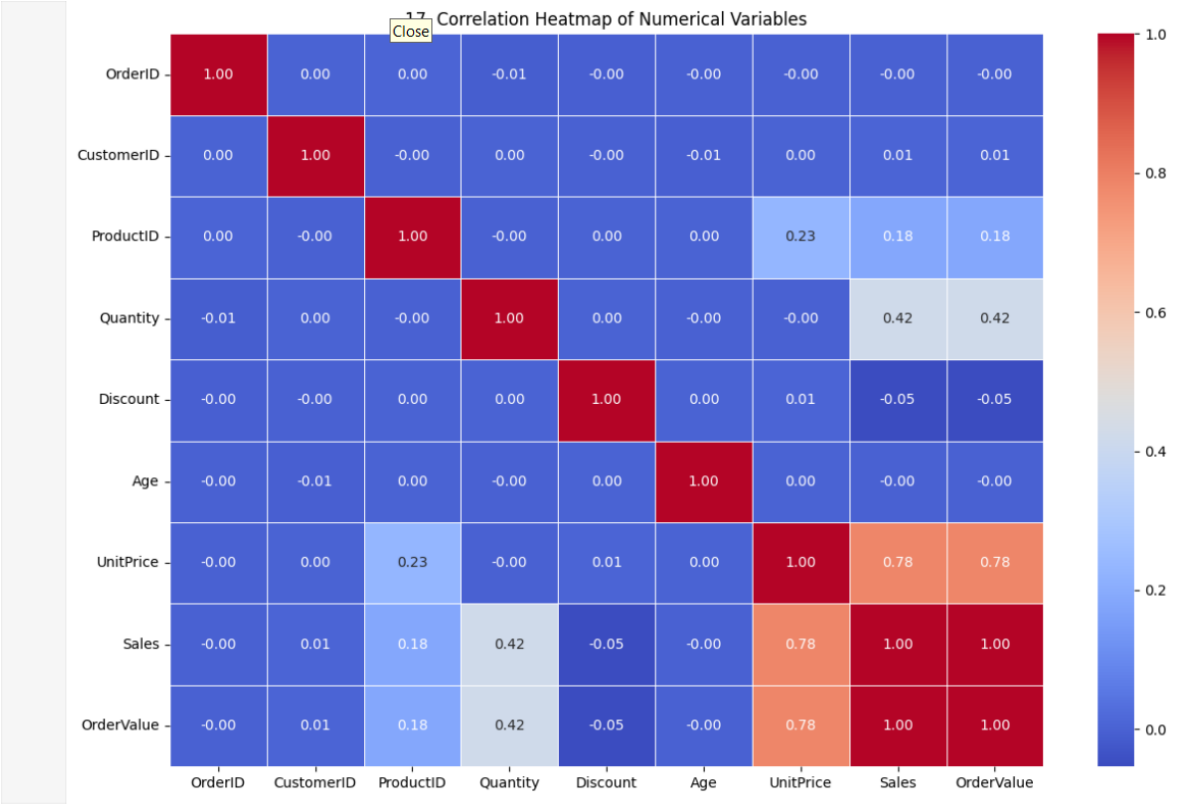
Fungsi sns.barplot() digunakan untuk menampilkan jumlah data pada setiap kategori target dalam bentuk batang. Sumbu horizontal menunjukkan kategori revenue contribution by customer segment, sedangkan sumbu vertikal menunjukkan jumlah data pada setiap kategori.

Visualisasi ini mempermudah perbandingan jumlah data antarkelas. Berdasarkan hasil perhitungan sebelumnya, batang kategori Moderate akan lebih tinggi dibandingkan kategori High dan Low. Grafik ini memperjelas bahwa distribusi kelas target tidak seimbang.

10. Menganalisis Korelasi Antarfitur Numerik

Tahap terakhir dalam EDA pada notebook ini adalah melihat korelasi antarfitur numerik menggunakan correlation matrix yang divisualisasikan dengan heatmap.

```
fig = plt.figure(figsize=(12,8))
corr = df.select_dtypes(include='number').corr()
sns.heatmap(corr, annot=True, cmap='coolwarm', fmt='.2f', linewidths=0.5)
plt.title(f'{plot_no}. Correlation Heatmap of Numerical Variables')
show_fig()
plot_no += 1
```



annot=True: menampilkan angka korelasi di setiap kotak. cmap='magma': menggunakan gradasi warna magma.Heatmap membantu mengidentifikasi pasangan fitur numerik yang memiliki korelasi relatif kuat maupun lemah. fmt='.2f': menampilkan angka dengan dua angka di belakang koma. linewidths=0.5: memberikan garis pemisah antarkotak. apabila korelasi antara jumlah barang dan total penjualan bernilai 0.85, kedua variabel tersebut memiliki hubungan linear positif yang kuat. Namun, korelasi tidak membuktikan hubungan sebab-akibat.

Informasi ini dapat digunakan untuk memahami pola hubungan antarvariabel dan menjadi bahan pertimbangan dalam pengolahan data berikutnya. Namun, korelasi tidak membuktikan hubungan sebabakibat. Selain itu, korelasi yang dihitung pada notebook ini hanya mencakup fitur numerik sehingga tidak secara langsung menggambarkan hubungan semua fitur kategorikal dengan target.

11. Hasil Eksplorasi Data

Berdasarkan seluruh pemeriksaan yang dilakukan, EDA memberikan gambaran awal mengenai kondisi dataset Stroke Risk Prediction. Dataset terdiri atas 49.222 baris dan 16 kolom, memiliki sejumlah fitur numerik dan kategorikal, tidak ditemukan baris yang sepenuhnya duplikat, serta terdapat missing value pada beberapa fitur.

Visualisasi histogram dan box plot digunakan untuk memeriksa distribusi dan penyebaran fitur numerik. Pemeriksaan BMI memberikan informasi mengenai frekuensi nilai, sedangkan pemeriksaan E-Commerce Sales Data Analysis & EDA menunjukkan bahwa kategori Moderate merupakan kelas dengan jumlah data terbesar. Heatmap korelasi digunakan untuk mengeksplorasi hubungan linear antarfitur numerik.

Hasil EDA tersebut menjadi dasar untuk menentukan hal-hal yang perlu diperhatikan sebelum data digunakan dalam pemodelan Machine Learning. Tahap selanjutnya adalah preprocessing, yang mencakup penanganan missing value, pengodean fitur kategorikal, dan standardisasi fitur numerik sesuai kebutuhan.

C. KESIMPULAN

Exploratory Data Analysis (EDA) merupakan tahap penting dalam proses Machine Learning karena membantu memahami struktur, karakteristik, dan kondisi dataset sebelum dilakukan preprocessing serta pembangunan model. Pada praktikum ini, EDA dilakukan menggunakan Jupyter Notebook dengan bantuan Pandas, Matplotlib, dan Seaborn untuk mengeksplorasi Stroke Risk Prediction Dataset.

Hasil pemeriksaan menunjukkan bahwa dataset memiliki 49.222 baris dan 16 kolom. Pemeriksaan struktur data memperlihatkan adanya fitur numerik dan kategorikal, sedangkan pemeriksaan data duplikat menunjukkan bahwa tidak terdapat baris yang sepenuhnya duplikat. Di sisi lain, ditemukan missing value pada beberapa fitur, seperti Age, Height_cm, Weight_kg, dan sejumlah indikator kesehatan lainnya. Temuan tersebut perlu diperhatikan ketika menentukan strategi preprocessing.

Visualisasi histogram dan box plot digunakan untuk memahami distribusi serta penyebaran fitur numerik. Pemeriksaan distribusi target menunjukkan bahwa kelasHal tersebut memperlihatkan bahwa jumlah data pada setiap kelas target tidak merata. Sementara itu, correlation matrix digunakan untuk mengeksplorasi hubungan linear antarfitur numerik.

Secara keseluruhan, proses EDA memberikan informasi awal mengenai kualitas dan karakteristik dataset serta membantu mengidentifikasi hal-hal yang perlu diperhatikan sebelum pemodelan dilakukan. Hasil eksplorasi ini akan digunakan sebagai dasar untuk melanjutkan ke tahap preprocessing, yaitu mempersiapkan data agar dapat digunakan dalam proses pelatihan dan evaluasi model Machine Learning.

PERTEMUAN 7 DATA PREPROCESSING, DATA TRANSFORMATION DAN DATA SPLITTING

A. LANDASAN TEORI

Data preprocessing, data transformation, dan data splitting merupakan tahapan penting dalam proses persiapan dataset sebelum digunakan untuk membangun model Machine Learning. Ketiga tahapan ini memiliki fungsi yang saling berkaitan, yaitu memastikan data memiliki kualitas yang baik, mengubah data ke dalam format yang sesuai dengan algoritma, serta membagi dataset untuk keperluan pelatihan dan pengujian model. Persiapan data yang tepat dapat membantu proses pembelajaran model berjalan lebih terstruktur dan menghasilkan evaluasi yang lebih objektif.

Data preprocessing merupakan proses pengolahan awal yang dilakukan untuk memeriksa, membersihkan, dan menyiapkan data sebelum digunakan dalam pemodelan. Pada tahap ini, pemeriksaan dapat dilakukan terhadap nilai yang hilang (missing values), data duplikat, tipe data, dan kemungkinan adanya nilai ekstrem (outlier). Nilai yang hilang dapat ditangani dengan menghapus data atau mengisi nilai menggunakan metode tertentu, seperti mean, median, atau modus. Pemilihan metode perlu disesuaikan dengan karakteristik fitur agar informasi penting dalam dataset tetap dipertahankan.

Data splitting merupakan proses membagi dataset menjadi beberapa bagian untuk kebutuhan pelatihan dan pengujian model. Pembagian yang umum digunakan adalah data latih (training data) dan data uji (testing data). Data latih digunakan untuk membantu model mempelajari pola dari data, sedangkan data uji digunakan untuk mengevaluasi kemampuan model terhadap data yang tidak digunakan selama pelatihan. Proses pembagian dapat dilakukan menggunakan fungsi train_test_split() dari Scikit-learn. Parameter seperti test_size, random_state, dan stratify dapat digunakan untuk mengatur proporsi data, menjaga konsistensi pembagian, serta mempertahankan proporsi kelas target jika diperlukan.

Data transformation merupakan proses mengubah representasi atau skala fitur agar sesuai dengan kebutuhan algoritma Machine Learning. Salah satu bentuk transformasi adalah encoding, yaitu mengubah fitur kategorikal menjadi bentuk numerik. Metode seperti OneHotEncoder dapat digunakan untuk kategori yang tidak

memiliki urutan, sedangkan metode encoding lainnya dapat dipilih apabila kategori memiliki urutan yang bermakna. Selain itu, feature scaling digunakan untuk menyesuaikan skala fitur numerik melalui metode seperti StandardScaler atau MinMaxScaler. Transformasi ini terutama berguna bagi algoritma yang sensitif terhadap perbedaan skala fitur.

Dalam penerapannya, tahapan preprocessing dan transformation perlu dilakukan dengan memperhatikan urutan pengolahan data untuk mencegah data leakage, yaitu kondisi ketika informasi dari data uji ikut memengaruhi proses pembelajaran model. Oleh karena itu, data umumnya dibagi terlebih dahulu sebelum parameter imputasi, encoding, dan scaling dipelajari dari data. Pada praktikum ini, ketiga tahapan diterapkan pada E-Commerce Sales Data Analysis & EDA Dataset menggunakan Python, Pandas, dan Scikit-learn sebagai persiapan sebelum memasuki tahap pembangunan model klasifikasi risiko stroke.

B. TUGAS PRAKTIKUM 1. Menghapus Kolom yang Tidak Digunakan

Setelah memeriksa struktur data, dilakukan penghapusan empat kolom yang tidak digunakan sebagai fitur model. Kolom tersebut adalah

```
X = df.drop(columns=['OrderValue', 'Sales', 'Quantity', 'Discount', 'UnitPrice']).copy()
y = df['OrderValue'].copy()
```

```
for col in ['OrderDate', 'SignupDate']:
    X[col] = pd.to_datetime(X[col], errors='coerce')
    X[col + '_Year'] = X[col].dt.year
    X[col + '_Month'] = X[col].dt.month
    X[col + '_Day'] = X[col].dt.day
    X[col + '_DayOfWeek'] = X[col].dt.dayofweek
    X.drop(columns=[col], inplace=True)
```

```
X.drop(columns=['OrderID', 'CustomerID', 'ProductID'], errors='ignore', inplace=True)
```

Kolom **Memisahkan Target dan Fitur (X dan y):** Menjadikan kolom OrderValue sebagai target prediksi (y) serta menghapus kolom target dan penjualan dari fitur (X) untuk mencegah kebocoran data. **Ekstraksi Fitur Tanggal:** Mengubah kolom teks tanggal (OrderDate dan SignupDate) menjadi komponen numerik yang lebih mudah dibaca model (Tahun, Bulan, Hari, dan Hari dalam seminggu).

Menghapus Kolom ID: Membuang kolom pengenal unik seperti OrderID, CustomerID, dan ProductID agar model tidak mengalami *overfitting*.

3. Memisahkan Fitur dan Target

Dataset yang telah diseleksi kemudian dipisahkan menjadi variabel fitur (X) dan target (y). Fitur merupakan informasi yang digunakan model untuk membuat prediksi, sedangkan target merupakan kategori yang ingin diprediksi.

```
import sklearn
#Memisahkan fitur (x) dan target (y)
x = df_lencoder.drop(columns=['SalePrice'])
y = df_lencoder['SalePrice']
```

```
from sklearn.model_selection import train_test_split

#Membagi dataset menjadi training dan testing
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=1)
```

Memisahkan Fitur dan Target: Variabel y ditetapkan sebagai kolom yang ingin diprediksi ('SalePrice'), sedangkan variabel x berisi kolom-kolom fitur lainnya.

Membagi Data Latih dan Uji (train_test_split): Memecah dataset menjadi data *training* (80%) untuk melatih model dan data *testing* (20%) untuk menguji performa model dengan pembagian yang konsisten berkat random_state=1

4. Membagi Data Training dan Testing

Tahap selanjutnya adalah membagi fitur dan target menjadi data pelatihan dan data pengujian. Pembagian dilakukan dengan proporsi 80:20.

```
# menghitung panjang/jumlah data
print("Jumlah data: ",len(x))
# menghitung panjang/jumlah data pada x_train
print("Jumlah data latih: ",len(x_train))
# menghitung panjang/jumlah data pada x_test
print("Jumlah data test: ",len(x_test))
```

```
Jumlah data:  557
Jumlah data latih:  445
Jumlah data test:  112
```

Parameter **len(x)**: Menghitung total keseluruhan data fitur, yaitu sebanyak **557 baris**. **len(x_train)**: Menghitung jumlah data yang dialokasikan untuk pelatihan model (*training*), yaitu sebanyak **445 baris**. **len(x_test)**: Menghitung jumlah data yang dialokasikan untuk pengujian model (*testing*), yaitu sebanyak **112 baris**.

5. Mengelompokkan Fitur Berdasarkan Jenisnya

Setelah data dibagi, fitur dikelompokkan berdasarkan jenis dan metode transformasi yang sesuai. Pengelompokan ini digunakan sebagai dasar dalam membangun ColumnTransformer

Pengelompokan tersebut diperlukan karena fitur numerik akan melalui imputasi median dan standardisasi, fitur ordinal akan melalui imputasi modus dan encoding berurutan, sedangkan fitur nominal akan melalui imputasi modus dan one-hot encoding.

C. KESIMPULAN

Berdasarkan praktikum yang dilakukan, tahapan data loading, data cleaning, dan Exploratory Data Analysis (EDA) sangat penting dalam proses analisis data penjualan e-commerce. Proses meliputi pengambilan dataset, pemeriksaan struktur data, penanganan missing values dan duplikasi, serta analisis karakteristik data menggunakan statistik deskriptif dan visualisasi. Analisis dilakukan untuk memahami pola penjualan, mengidentifikasi produk yang berpotensi diminati, serta mengetahui tren transaksi berdasarkan data yang tersedia. Dengan tahapan tersebut, data penjualan e-commerce dapat digunakan untuk memperoleh informasi yang bermanfaat dalam mendukung pengambilan keputusan dan pengembangan strategi bisnis.

.

PERTEMUAN 8 MODELING DAN EVALUASI MODEL

A. LANDASAN TEORI

Tujuan praktikum ini adalah melakukan analisis data penjualan e-commerce untuk mengetahui karakteristik, pola, dan tren penjualan berdasarkan dataset yang digunakan. Analisis ini juga bertujuan memperoleh informasi yang dapat membantu pelaku bisnis dalam mengevaluasi penjualan dan menentukan strategi pemasaran.

Data analysis merupakan proses pengolahan dan pemeriksaan data untuk menghasilkan informasi yang berguna. Dalam praktikum ini, analisis dilakukan menggunakan dataset E-Commerce Sales Data Analysis and EDA dengan bantuan Python dan pustaka Pandas, Matplotlib, serta Seaborn.

Tahapan praktikum meliputi pemuatan dataset, pemeriksaan struktur data, pembersihan data, analisis statistik deskriptif, dan visualisasi data. Proses tersebut dilakukan untuk memahami karakteristik dataset, memeriksa kualitas data, serta menemukan pola penjualan yang dapat dianalisis lebih lanjut.

Hasil analisis diinterpretasikan berdasarkan informasi yang tersedia dalam dataset, seperti jumlah transaksi, nilai penjualan, produk yang diminati, dan tren penjualan apabila variabel tersebut tersedia. Informasi yang diperoleh dapat digunakan untuk memahami kondisi penjualan serta mendukung pengambilan keputusan bisnis.

Visualisasi data digunakan untuk menyajikan hasil analisis dalam bentuk grafik agar lebih mudah dipahami. Grafik batang dapat digunakan untuk membandingkan penjualan, grafik garis untuk mengamati perubahan penjualan berdasarkan waktu, dan histogram untuk melihat distribusi data numerik. Dengan demikian, praktikum ini membantu memahami penerapan Exploratory Data Analysis (EDA) dalam mengidentifikasi pola penjualan dan menghasilkan informasi yang bermanfaat bagi pengembangan bisnis e-commerce.

B. TUGAS PRAKTIKUM

1. Membuat penampilan modelling tentang data penjualan

histogram dan kurva distribusi umur pelanggan (*Customer Age Distribution*). Langkah-langkah utamanya meliputi: Mengambil data dari kolom "Age", membersihkan nilai yang kosong, lalu membaginya ke dalam 25 kelompok (*bins*) beserta garis tren distribusi (kde=True). Mengatur visualisasi grafik dengan warna hijau medium (*mediumseagreen*), ukuran kanvas, judul, label sumbu X dan Y, serta garis bantu (*grid*)

```
plt.figure(figsize=(10, 6))

sns.histplot(
    df["Age"].dropna(),
    bins=25,
    kde=True,
    color="mediumseagreen"
)

plt.title("Customer Age Distribution")
plt.xlabel("Age")
plt.ylabel("Number of Customers")
plt.grid(alpha=0.2)
plt.show()
```

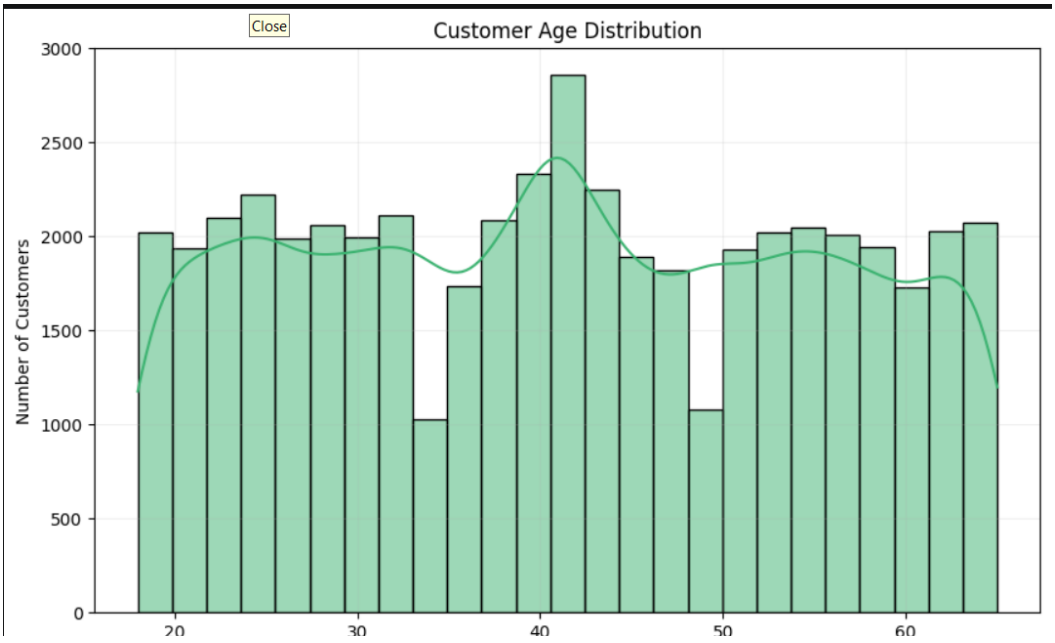


diagram tersebut menunjukkan bahwa:**Rentang Usia:** Pelanggan mencakup usia 18 hingga 65 tahun. Jumlah Terbanyak: Kelompok usia terbanyak berada pada

sekitar 40–42 tahun (hampir 3.000 pelanggan). Penurunan Terendah**:** Jumlah pelanggan paling sedikit terlihat pada usia sekitar **34** tahun dan 49 tahun (hanya sekitar 1.000 pelanggan).

Rata-rata Sebaran: Di luar titik puncak dan penurunan tersebut, sebaran pelanggan di usia lainnya relatif stabil pada angka 1.800–2.200 orang

2. menganalisis dan memvisualisasikan total penjualan berdasarkan segmen pelanggan dalam bentuk diagram batang (*bar chart*).

```
segment_sales = (
    df.groupby("CustomerSegment")["Sales"]
    .sum()
    .sort_values(ascending=False)
)

plt.figure(figsize=(10, 6))

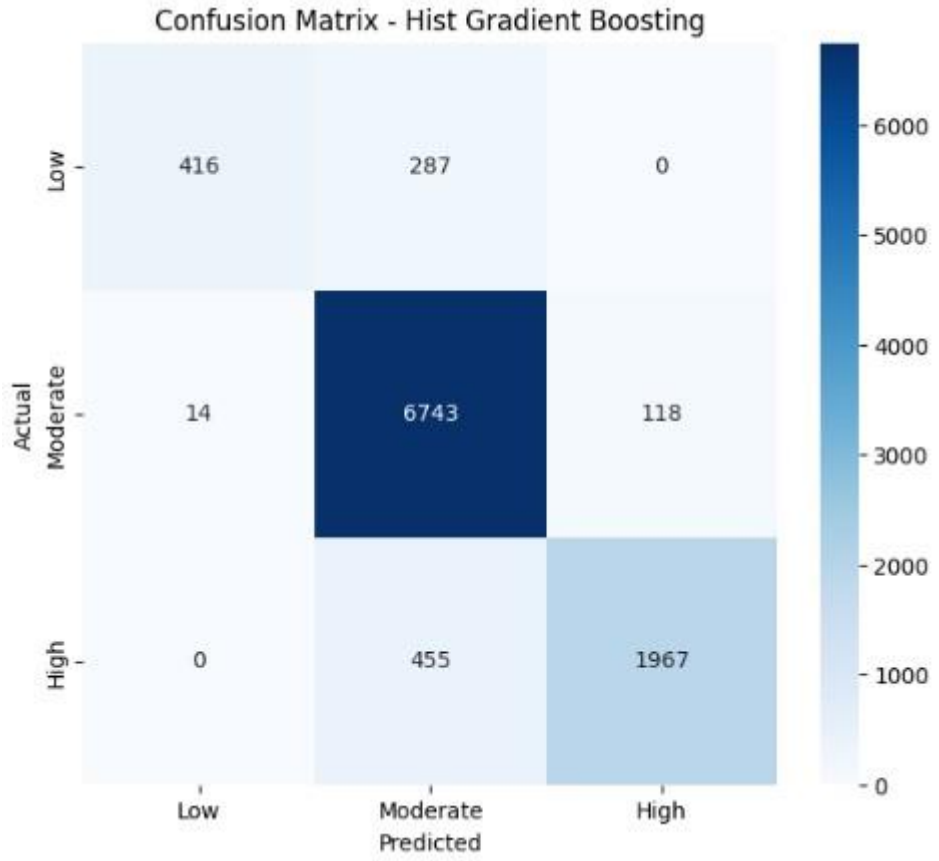
sns.barplot(
    x=segment_sales.index,
    y=segment_sales.values,
    color="mediumblue"
)

plt.title("Sales by Customer Segment")
plt.xlabel("Customer Segment")
plt.ylabel("Total Sales")
plt.xticks(rotation=45)
plt.grid(axis="y", alpha=0.2)
plt.show()
```

Mengelompokkan data berdasarkan segmen pelanggan, menjumlahkan total penjualannya,lalu mengurutkannya dari yang terbesar. Membuat grafik diagram batangmenggunakan pustaka Seaborn dengan warna biru medium (*mediumblue*). Menyesuaikan tampilan grafik seperti memberikan judul, melabeli sumbu X dan Y, memutar teks label sumbu X sebesar 45 derajat agar mudah dibaca, serta menambahkan garis bantu (*grid*)



menunjukkan total penjualan berdasarkan segmen pelanggan dan kategori produk. Kategori Terlaris: *Electronics* menjadi produk dengan penjualan tertinggi di semuasegmen. Segmen Dominan: Segmen *Regular* mencatatkan angka penjualan tertinggi secarkeseluruhan, terutama pada kategori *Electronics* (mencapai 966.594). Penjualan Terendah: *Stationery* adalah kategori dengan total penjualan paling rendah di semua segmen pelanggan



Pada Confusion Matrix tiga kelas, nilai diagonal menunjukkan jumlah data yang berhasil diklasifikasikan dengan benar. Sementara itu, nilai di luar diagonal menunjukkan jumlah data yang diprediksi ke kategori yang berbeda dari kelas sebenarnya. Sebagai contoh, data aktual Low yang diprediksi sebagai Moderate merupakan kesalahan klasifikasi antara dua kategori tersebut.

```
print("\n" + "=" * 70)
print("BUSINESS SUMMARY")
print("=" * 70)

print("Total Orders       :", df["OrderID"].nunique())
print("Total Customers    :", df["CustomerID"].nunique())
print("Total Products     :", df["ProductID"].nunique())
print("Total Quantity     :", df["Quantity"].sum())
print("Total Sales        :", round(df["Sales"].sum(), 2))
print("Total Order Value  :", round(df["OrderValue"].sum(), 2))
print("Average Sales      :", round(df["Sales"].mean(), 2))
print("Average OrderValue :", round(df["OrderValue"].mean(), 2))
print("Average Discount   :", round(df["Discount"].mean(), 2))
print("Average Age        :", round(df["Age"].mean(), 2))
```

Total Keseluruhan: Menghitung jumlah unik pesanan, pelanggan, produk, total kuantitas barang terjual, serta total nilai penjualan. Nilai Rata-rata: Menghitung rata-rata penjualan, nilai pesanan, besar diskon, dan usia pelanggan (dibulatkan hingga 2 angka desimal).

```
======================================================================
BUSINESS SUMMARY
======================================================================
Total Orders       : 49222
Total Customers    : 9820
Total Products     : 20
Total Quantity     : 92632.0
Total Sales        : 3444830.0
Total Order Value  : 3444830.0
Average Sales      : 69.99
Average OrderValue : 69.99
Average Discount   : 7.49
Average Age        : 41.28

Best Category by Sales: Electronics
Best Product by Sales: Headphones
Best City by Sales: Tehran
Most Used Payment Method: Gateway
Most Common Customer Segment: Regular

======================================================================
VISUALIZATION COMPLETED SUCCESSFULLY
======================================================================
```

menampilkan hasil akhir laporan ringkasan bisnis (*Business Summary*) dari data yang telah dianalisis. Rincian utamanya meliputi: Metrik Bisnis: Menunjukkan total 49.222 pesanan, 9.820 pelanggan, total penjualan 3.444.830, serta rata-rata usia pelanggan 41,28tahun. Performa Terbaik: Kategori produk terlaris adalah *Electronics* (*Headphones* sebagai produk terbaik), kota dengan penjualan tertinggi adalah *Tehran*, metode pembayaran terpopuler adalah *Gateway*, dan mayoritas pelanggan berasal dari segmen *Regular*. Status Program: Di bagian bawah terdapat pesan penutup

"VISUALIZATION COMPLETEDSUCCESSFULLY" yang menandakan seluruh proses analisis dan visualisasi data telah sukses dijalankan.

C. KESIMPULAN

Berdasarkan praktikum yang dilakukan, proses analisis data pada dataset E-Commerce Sales Data Analysis and EDA berhasil menghasilkan ringkasan informasi bisnis melalui tahapan data loading, data cleaning, Exploratory Data Analysis (EDA), dan visualisasi data. Hasil analisis menunjukkan terdapat 49.222 pesanan, 9.820 pelanggan, total penjualan sebesar 3.444.830, serta rata-rata usia pelanggan 41,28 tahun.

Berdasarkan ringkasan bisnis, kategori produk dengan performa terbaik adalah Electronics, dengan Headphones sebagai produk terbaik. Kota dengan penjualan tertinggi adalah Tehran, metode pembayaran yang paling populer adalah Gateway, dan mayoritas pelanggan termasuk dalam segmen Regular. Informasi tersebut dapat digunakan untuk memahami karakteristik penjualan, preferensi pelanggan, serta kondisi bisnis e-commerce.

Proses visualisasi data juga berhasil diselesaikan, yang ditandai dengan pesan “VISUALIZATION COMPLETED SUCCESSFULLY”. Secara keseluruhan, praktikum ini menunjukkan bahwa analisis data dan visualisasi dapat membantu menyajikan informasi bisnis secara lebih terstruktur dan mudah dipahami. Hasil analisis tersebut dapat menjadi bahan pertimbangan dalam mengevaluasi penjualan dan menyusun strategi bisnis yang lebih tepat berdasarkan data yang tersedia.